

“Métricas custom para reducción de falsos positivos en  
clasificación binaria - fraude”

## Informe Técnico: Detección de Fraudes Financieros con LightGBM

---

### 1. Resumen

Se abordó el reto de optimizar la detección de fraudes en un dataset de transacciones bancarias realizadas dentro de EE.UU., simulando transacciones internacionales y aplicando múltiples estrategias de ingeniería de variables y evaluación personalizada. Se entrenaron modelos LightGBM con métricas clásicas y funciones de evaluación personalizadas. El objetivo final fue reducir los falsos positivos sin afectar significativamente el recall.

### 2. Metodología

Simulación de transacciones internacionales:

- Se asignó a cada estado un centro geográfico (centroide) y un radio máximo estimado.
- Se calculó la distancia entre la transacción y el centroide mediante la fórmula de Haversine.
- Si la distancia excedía el radio del estado, se etiquetó como transacción internacional (`is_international = 1`).

Ingeniería de Características Geográficas:

- Variables como `dist_to_state_center`, `state_radius_ratio`, `is_borderline`, `extreme_distance_flag`, `dist_category`, `distance_diff_from_limit`, `is_centered`, entre otras.

Ingeniería de Variables Generales:

- `time_since_last_tx`: tiempo desde la última transacción.
- `delta_amt`: diferencia de monto entre transacciones.

- tx\_rolling\_freq: frecuencia de las últimas 5 transacciones.
- z\_amt: z-score por cliente del monto.
- merchant\_tx\_count, repeat\_rate, amt\_ratio\_month, merchant\_repeat, days\_since\_last\_tx.

Entrenamiento con LightGBM:

- Entrenamiento inicial con AUC > 0.999, umbral estándar (0.5).
- Ajuste de umbral usando best\_threshold\_v3() para maximizar F1 manteniendo Recall  $\geq 0.90$ .

Métricas personalizadas:

- feval\_ratio\_fp\_tp: penaliza falsos positivos.
- feval\_f1\_penalized: penaliza el F1 si hay muchos FP.
- feval\_precision\_at\_recall: requiere recall  $\geq 0.5$  para validar la precisión.

### 3. Implementación Práctica

- Dataset filtrado temporalmente (diciembre 2020 como test).
- SMOTE aplicado en transacciones internacionales
- Entrenamiento de tres modelos con distintas estrategias:
  - Ponderación de clases.
  - Métrica personalizada por modelo.
  - Optimizado por umbral con Recall  $\geq 0.8/0.9$  y Ratio FP/TP  $\leq 2.0/3.0$ .

## 4. Análisis de Resultados

### 4.1 Modelo General (Full dataset)

Conjunto	AUC	Precisión	Recall	F1	Ratio FP/TP
Validación (0.5)	0.9997	0.946	0.919	0.933	1.057
Test (0.5)	0.9983	0.934	0.818	0.872	1.071
Test (0.0079)	0.9983	0.698	0.903	0.787	1.433

#### 4.2 Modelo sobre Transacciones Internacionales

Conjunto	AUC	Precisión	Recall	F1	Ratio FP/TP
Test	0.9989	0.879	0.764	0.817	1.137

#### 4.3 Modelos con Métricas Personalizadas

Modelo	AUC	Precisión	Recall	F1	Ratio FP/TP	Umbral
F1_Penalizado	0.9981	0.922	0.822	0.869	1.085	0.7075
Precision@Recall $\geq$ 0.8	0.9890	0.746	0.806	0.775	1.341	0.0051
Ratio_FP_TP	0.9780	0.560	0.802	0.659	1.787	0.0111

### 5. Conclusiones

- Modelo General: excelente separación con  $AUC > 0.998$ . Ajustar el umbral permite alcanzar  $Recall \geq 90\%$  con aceptable precisión (69.8%).
- Modelo Internacional: muy útil para contextos geográficamente anómalos, mantiene alta  $AUC$  y  $ratio\ FP/TP$  bajo.
- Modelo con F1\_Penalizado: mejor balance general. Precisión  $> 92\%$ , recall  $> 82\%$ ,  $ratio\ FP/TP \leq 1.1$ .
- Recomendación: utilizar el modelo F1\_Penalizado en producción, con validación sobre el umbral ajustado, monitoreo continuo de falsos positivos y refinamiento periódico del modelo.